

The Landscape of Emerging AI Agent Architectures for Reasoning, Planning, and Tool Calling: A Survey

등반자팀
이진선

목적

- 기존 AI 에이전트 구현의 현재 능력과 한계를 전달
- 시스템이 실제로 작동하는 모습을 관찰하면서 얻은 통찰을 공유
- AI 에이전트 설계의 미래 발전을 위한 중요한 고려사항을 제시

서론

RAG(Retrieval Augmented Generation)



분류

Agents : 언어 모델 기반으로 계획하고 실행하며, 단일 또는 다중 구조로 구성

Agent Persona : 에이전트의 역할, 성격, 도구 사용 방식을 정의하며, 성능에 직접적 영향

Tools : 외부와 상호작용할 수 있게 해주는 함수로, 정보 조회·저장 등을 가능

Single Agent Architectures : 하나의 언어 모델이 모든 작업을 혼자 처리하며, 에이전트 간 피드백은 존재하지 않음

Multi-Agent Architectures : 여러 에이전트가 협력하여 작업하며, 모델·도구·역할을 분담

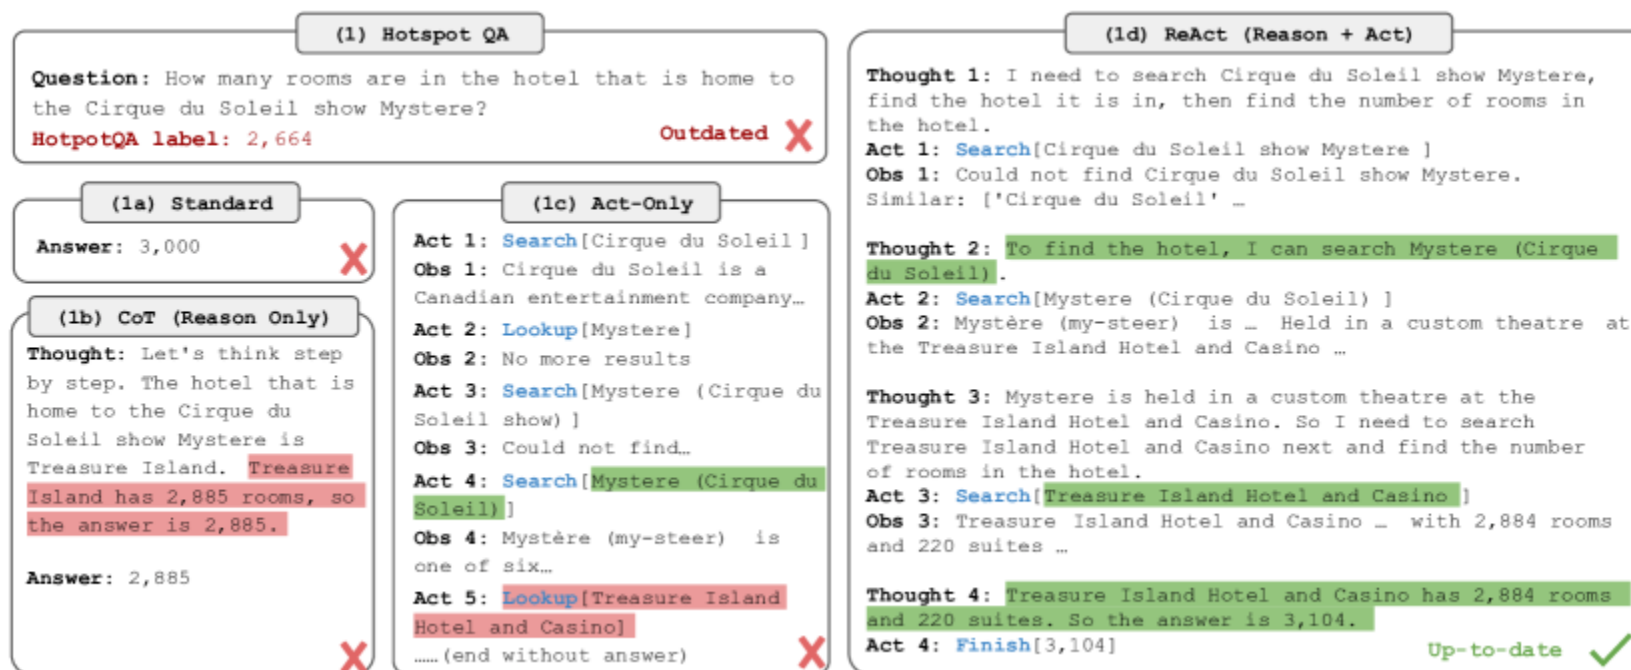
Vertical Architectures : 리더 에이전트가 중심이 되어 다른 에이전트들을 지휘·조율

Horizontal Architectures : 모든 에이전트가 동등하게 협업하며, 자율적으로 소통하고 행동

효과적인 에이전트를 위한 주요 고려 사항

- **에이전트의 개요**
에이전트는 언어 모델을 확장해 실제 문제를 해결하며, 문제 해결 능력, 추론과 계획 수립, 외부 도구와의 상호작용이 필요
- **추론과 계획 수립의 중요성**
추론은 자율적 문제 해결에 필수적이며, 계획 수립은 작업을 효율적으로 나누고 선택하는 과정
- **도구 호출의 중요성**
에이전트는 외부 도구를 사용해 복잡한 문제를 해결하며, 다중 에이전트 시스템은 효율성 증가 기여


Single Agent Architectures



- ReAct (Reason + Act)
주어진 작업에 대해 생각 작성 -> 생각을 바탕으로 행동 -> 결과를 관찰
=> 작업이 완료 될 때 까지 추론, 관찰, 행동 반복하여 신뢰성 증가

➔ ReAct 루프에서 벗어나지 못하는 경우 발생 가능
해결방안) 작업 수행 중 인간의 피드백 통합

Single Agent Architectures



- RAISE

ReAct 방법을 기반으로 하며, 인간의 단기 및 장기 기억을 모방하는 메모리 메커니즘이 추가된 방법

단기 정보 : 스크래치패드에 저장

장기 정보 : 이전의 비슷한 사례들을 데이터셋으로 저장

- ➔ 복잡한 논리 이해 어려움으로 많은 시나리오에서 유용성 제한, 자신의 역할이나 지식에 대해 잘못된 정보 생성
해결방안) 모델을 세밀하게 조정하여 해결

Single Agent Architectures

- Reflexion


언어적 피드백을 통한 자기 반성을 활용하는 단일 에이전트 패턴.

성공 상태, 현재 진행 경로, 지속적인 기억과 같은 지표를 활용하여 LLM 평가자가 에이전트에게 구체적이고 관련성 있는 피드백을 제공하여 성공률 향상.

Chain-of-Thought와 ReAct에 비해 허위 생성이 감소.

➔ "Non-optimal local minima solutions" 취약, 슬라이딩 윈도우 사용하여 장기 기억 용량 제한 해결방안) 다양성, 탐색 및 추론이 중요한 작업에서 성능을 개선할 여지

Single Agent Architectures



- AutoGPT + P (Planning)

자연어로 로봇을 제어하는 에이전트의 추론 제한을 해결하는 방법으로 객체 탐지와 객체 활용도 매핑을 LLM 기반 계획 시스템과 결합.

이미지 분석을 통해 객체를 탐지

계획 도구(Plan Tool) / 부분 계획 도구(Partial Plan Tool) / 대안 제시 도구(Suggest Alternative Tool)

/ 탐색 도구(Explore Tool) 도구 중 하나를 선택

목표를 완료하기 위한 전체 계획을 생성

➔ 도구 선택의 정확도 문제와 탐색에서의 비논리적인 결정, 제한된 인간 상호작용

Single Agent Architectures

- LATS (Language Agent Tree Search)
계획, 행동, 추론을 결합한 단일 에이전트 방식으로, 트리 구조를 사용하여 작업을 수행.

자기 반성적 추론


: 행동을 취한 후 환경의 피드백과 언어 모델의 피드백을 통해 추론 오류 확인 후 대안 제시

효율적인 검색 알고리즘

- : 강력한 검색 알고리즘과 결합된 자기 반성 능력으로 다양한 작업에서 뛰어난 성능


➔ 고급 계산 자원과 긴 처리 시간을 요구, 복잡한 시나리오에 대한 테스트가 부족

Multi-Agent Architectures



- Embodied LLM Agents Learn to Cooperate in Organized Teams (Guo et al.의 연구)
리더 에이전트가 에이전트 팀의 전반적인 효율성에 미치는 영향을 보여줌.
계획 생성, 성능 평가, 피드백 제공, 팀 재구성을 위한 “비판-반성” 단계를 적용하는 것의 중요성을 강조.
리더십과 동적 팀 구조 -> 추론, 계획, 작업 수행을 더 효과적으로 할 수 있도록 개선.
- DyLAN(Dynamic LLM-Agent Network)
추론 및 코드 생성과 같은 복잡한 작업에 초점을 맞춘 동적 에이전트 구조 생성.
각 에이전트가 지난 작업에서 얼마나 기여했는지 평가 -> 다음 작업 수행 시 상위 기여자 선택(수평적 성격)
산술 및 일반 추론 능력을 측정하는 다양한 벤치마크에서 향상된 성과 표출.

Multi-Agent Architectures



- **AgentVerse**
그룹 계획을 위한 단계들이 에이전트의 추론 및 문제 해결 능력을 어떻게 향상시킬 수 있는지 보여줌.

모집, 협업적 의사결정, 독립적 행동 실행, 평가
(recruitment, collaborative decision making, independent action execution, evaluation)
위 과정은 전체 목표가 달성될 때 까지 반복

Multi-Agent Architectures

- MetaGPT
에이전트들 간의 생산적이지 않은 대화 문제 해결을 위해,
에이전트 간 비구조화된 채팅을 공유하는 대신, **publish-subscribe**(발행-구독) 매커니즘 구현하여 정보 공유

토론과 관찰

에이전트 구현은 문제를 반복적으로 해결하기 위해 **계획 - 실행 - 평가** 과정 따름.

단일 에이전트와 멀티 에이전트 아키텍처 모두 복잡한 목표 실행에서 뛰어난 성과를 보인다고 판단.

두 아키텍처 모두 명확한 피드백, 작업 분해, 반복적인 개선, 역할 정의가 에이전트 성능을 향상시킨다는 사실을 발견.

- 단일 에이전트 vs 멀티 에이전트 아키텍처 선택을 위한 일반적인 조건
- 에이전트와 비동기 작업 실행
- 피드백과 인간의 감독이 에이전트 시스템에 미치는 영향
- 그룹 대화 및 정보 공유의 도전 과제
- 역할 정의 및 동적 팀의 영향

현재 연구의 한계 및 향후 연구 고려사항

- 에이전트 평가의 문제
- 데이터 오염 및 정적 벤치마크의 영향
- 벤치마크의 범위와 전이 가능성
- 실제 세계 적용 가능성
- 에이전트 시스템의 편향성과 공정성

결론

복잡한 목표를 협력하여 수행해야 하는 에이전트 팀을 구성 시
다음 요소 중 하나를 갖춘 에이전트를 배치하는 것이 유리

- 명확한 시스템 프롬프트 정의
- 명확한 리더십과 작업 분담
- 전담된 추론/계획-실행-평가 단계
- 동적 팀 구조
- 인간 또는 에이전트 피드백
- 지능적인 메시지 필터링

=> 단일 에이전트 아키텍처나 이러한 전략이 없는 멀티 에이전트 아키텍처보다 성능이 향상될 가능성이 큼